

MD RAKIBUL ISLAM RAIHAN

AI 工程师—大模型推理与多模态研究 (2027 届应届)

现居: 中国·西安·可接受异地·2027 年 7 月到岗
国籍: 孟加拉国·性别: 男·出生日期: 2002.12.06
语言: 孟加拉语(母语)·英语(流利)·中文(日常交流)
工作许可: 需办理中国工作签证(雇主担保 Z 签证)·全球: 接受担保
邮箱: raihanrakib.143@gmail.com·电话: +86-17722362949·微信: imeddii
LinkedIn: linkedin.com/in/theraihanrakib·GitHub: github.com/theraihanrakibb
作品集: theraihanrakibb.github.io/Online-Portfolio



个人简介

2027 届应届 AI 工程师, 专注大模型推理系统与多模态研究。在 **InfX.ai** 的 **4× A800** 集群上构建并部署大模型服务 (SGLang、KV-cache 卸载、PD 分离——缓存命中率 92.27%, TTFT 降低 8.3 倍)。IEEE TNNLS (Q1) 论文第一作者。求职方向: AI 工程师 / 算法研究员, 地点中国、香港或全球。

教育背景

软件工程硕士, 西北工业大学 (985/211) — 2024年9月 – 2027年7月
软件学院·GPA **88/100**·前 **1%**·中国政府奖学金
计算机科学与技术学士, 西北工业大学 (985/211) — 2020年9月 – 2024年7月
计算机学院·GPA **85/100**·前 **1%**·校长奖学金·最佳本科毕业论文奖

工作经历

无界智索 (深圳) 科技 (InfX.ai) | AI 基础设施工程师实习 | 深圳 | 2026年4月 – 2026年6月

- 通过 Mooncake RDMA 在 4× A800 上构建三级 KV-cache 卸载 (GPU HBM → CPU DRAM → SSD), 将 TTFT 降低 8.3 倍 (55s → 6.7s), 长上下文模型缓存命中率达 92.27%。
- 修改 SGLang 源码的缓存管理与内存分配模块 (kvcacheio.py、hiradix_cache.py、memory_pool_host.py), 修复生产缓存故障并部署混合注意力 Qwen 模型。
- 构建 PD 分离 (prefill/decode) 推理架构, 基于 RDMA 共享 KV, 稳定并发由 192 → 256 提升, 并通过 RadixAttention 前缀缓存与连续批处理提高 GPU 利用率。
- 使用 Nsight Systems 分析 CUDA/Triton 推理链路, 定位 GEMM 瓶颈, 经算子优化与 FP8 量化提升服务吞吐。
- 运用 Little's Law 建模容量上限, 论证 4× A800-80GB 上长上下文服务受限约 1.5 RPS, 指导扩容。
- 排查并解决 12+ 起生产故障 (RDMA、etcd、网络、存储与分布式推理)。
- 在 A800 集群部署 Qwen 模型 (单节点 TP2, 以及 TP4 PD prefill/decode 分离), 并在 H800 多节点集群 (每集群 8 卡) 运行 DeepSeek, 调优张量并行布局以提升吞吐与稳定性。

香港阿姆兰集团 (Amram Group) | 软件工程师实习 (AI Agent) | 深圳 | 2025年6月 – 2025年9月

- 基于 React、REST API 与后端自动化服务开发生产级全栈应用。
- 开发 AI Agent 工作流自动化系统, 运营效率提升 **25%**。

陕西龙工智能科技 (Longong) | 电气软件工程师实习 | 西安 | 2025年2月 – 2025年4月

- 基于 CODESYS 开勋 PLC 工业控制系统, 用于机器人与工业自动化。
- 实现 Modbus、CAN 与 Ethernet/IP 通信协议, 电机控制性能提升 **15%**。

研究经历

研究生研究员 | 西北工业大学 | 2024年9月 – 至今

导师: 张蓬 教授

- 开发 **NVFP4-DiT: 4 比特音频引导视频扩散 Transformer**, 显存降低 **4 倍**且保持生成质量。
- 实现多模态扩散 Transformer 的**低精度量化 (FP8/FP4/NVFP4)**, 评估质量-效率权衡。
- 在 **A800/H100** 上对 NVFP4-DiT 进行基准测试, 使用 PyTorch Profiler 与 Nsight 分析端到端延迟与显存, 指导低精度算子选型。
- 基于视觉、音频与时序一致性的多模态深度伪造检测研究。
- 硕士论文: 《检测深度伪造视频: 基于多模态音视频框架与时序不一致性》。

本科研究员 | 西北工业大学 | 2023年1月 – 2024年7月

导师: 陈亚星 博士

- 基于 Apache Spark 与 CKKS 同态加密设计并实现分布式机密查询框架, 通过优化分析管线实现**95% 隐私保护**与**20% 性能提升**。
- 本科论文: 《面向 Apache Spark 的分布式机密查询协议设计与实现》。

项目

AI 基础设施代码集 | github.com/theraihanrakibb/ai-infrastructure

- 10 个生产级、Docker 化的 AI 基础设施项目: LLM 网关、模型服务、GPU 可观测性、训练运维、MLOps 注册表、KV-cache 模拟器、基准测试、量化、链路追踪、RAG。

分布式训练启动器 | github.com/theraihanrakibb/train-launcher

- 用于启动与监控多节点 PyTorch 训练任务的命令行工具, 具备容错与自动重试; 降低分布式训练运维成本。

C 编译器 (前端) | github.com/theraihanrakibb/c-compiler-frontend

- 基于 Yacc/Lex 的自研 C 编译器前端 (词法/语法分析/代码生成); 体现系统与算法基础。

技术技能

编程语言	Python (主语言)、C、C++、Java、SQL、Bash
AI / ML	PyTorch、TensorFlow、Transformers、scikit-learn、NumPy; 深度学习、模型评估与指标
大模型与服务	大模型推理与服务 (SGLang、vLLM)、RAG、智能体、微调 (LoRA/QLoRA)、量化 (FP8/INT4)
GPU 与系统	CUDA、Triton、FlashAttention、多卡/分布式训练 (DDP、FSDP)、PyTorch Profiler、Nsight
计算机视觉与生成式 AI	CNN、Vision Transformers、扩散模型 (DDPM/DiT)、视频生成、多模态学习、OpenCV
数据与 MLOps	Pandas、SQL、Docker、Kubernetes、Git、CI/CD (GitHub Actions)、Slurm、AWS / GCP、Apache Spark、Weights & Biases / MLflow
数学与理论	线性代数、概率与统计、优化、凸优化、信息论
基础	数据结构与算法、并发、操作系统、计算机网络、分布式系统

在审论文与荣誉

论文: 第一作者, 《NVFP4-DiT: 面向低成本视频生成的高效 4 比特音频引导视频扩散 Transformer》— IEEE TNNLS (Q1), 审稿中。

荣誉: 中国政府奖学金 (2024–2027); 校长奖学金 (2020–2024); 最佳本科毕业论文奖 (2024); 西北工业大学优秀毕业生 (2024); NWPU AI 挑战赛黑客松冠军 (2023)。