MD RAKIBUL ISLAM RAIHAN

ML Systems Engineer | LLM Inference & Multimodal AI
2027 New Grad · Available July 2027 · Open to Relocation · Xi'an, China
Email: raihanrakib.143@gmail.com · Phone: +86 177 2236 2949
GitHub: github.com/theraihanrakibb · LinkedIn: linkedin.com/in/theraihanrakib · Portfolio: theraihanrakibb.github.io



SUMMARY

ML Systems Engineer focused on LLM inference, GPU optimization, and multimodal generative AI. At InfiX.ai, optimized production LLM serving - Qwen on 4× A800 and DeepSeek on multi-node H200 clusters - reducing long-context TTFT 8.3× (55s→6.7s) via 3-tier KV-cache offload and raising stable concurrency 192→256 via RDMA-based prefill/decode disaggregation. First author of an IEEE TNNLS manuscript on NVFP4 4-bit audio-guided video diffusion (4× memory reduction on H100). Strong in SGLang, CUDA/Triton, low-precision inference, and distributed systems.

EXPERIENCE

AI Infrastructure Engineer Intern, InfiX.ai, Shenzhen, China, Apr 2026 - Jun 2026

- Reduced long-context TTFT 8.3× (55s→6.7s) and sustained a **92%** cache hit rate by designing and deploying a 3-tier KV-cache offload system (GPU HBM → CPU DRAM → SSD) over Mooncake RDMA for Qwen3.5/3.6-27B on 4× A800-80GB (32K+ token contexts).
- Improved stable serving concurrency 33% (192→256 requests) by implementing 2+2 GPU prefill/decode disaggregation with RDMA-based KV transfer, RadixAttention prefix caching, and continuous batching for Qwen3.6-27B.
- Modified **SGLang** cache-management and memory-allocation internals (kvcacheio.py, memory_pool_host.py, hi_mamba_radix_cache.py) - across **v0.5.9** (A800) and **v0.5.10-post2** container image (H200) - to resolve production cache failures and support hybrid-attention (Mamba + full-attention) Qwen models.
- Profiled CUDA/Triton inference with **Nsight Systems**: GEMM accounted for **60%** of step time, redirecting optimization from cache I/O to compute kernels; FP8 KV cache halved per-token KV memory (72.9 → 36.5 KB).
- Deployed Qwen3-235B-A22B-FP8 (235B MoE) on 2× H200 and benchmarked DeepSeek-V3.2 (FP8) on 8× H200 - **91 ms TTFT / 36 ms TPOT** at 32-64 concurrency, **13.16 req/s** at 256 concurrency.

Software Engineer Intern (AI Agent), Hong Kong Amraim Group Co., Ltd., Shenzhen, China, Jun 2025 - Sep 2025

- Architected and delivered two end-to-end full-stack applications from concept to production deployment, using React front-ends and RESTful back-end services.
- Engineered AI agents that automated key marketing workflows, reducing manual effort and boosting team productivity by **25%**.

Electrical Software Engineer Intern, Shaanxi Longong Intelligent Technology Co., Ltd., Xi'an, China, Feb 2025 - Apr 2025

- Engineered real-time motor-control software on CODESYS PLCs using Modbus/CAN/Ethernet-IP protocols, improving system response time by **15%** to IEC 61131 industrial safety standards.

EDUCATION

M.Eng. in Software Engineering, School of Software, Northwestern Polytechnical University - Sep 2024 - Jul 2027
GPA: 88/100, Top 1%, Chinese Government Scholarship, President of International Student Union (ISU)

B.Eng. in Computer Science & Technology, School of Computer Science, Northwestern Polytechnical University - Sep 2020 - Jul 2024
GPA: 85/100, Top 1%, Presidential Scholarship, Best Undergraduate Thesis Award

RESEARCH

Graduate Researcher, Northwestern Polytechnical University, Sep 2024 - Present
Advisor: Prof. Zhang Peng

- Developed **NVFP4-DiT**, a **4-bit audio-guided video diffusion transformer**, with custom FP4-packed **Triton** kernels that are **3.2× faster than FP16** (2.1× over naive FP4) and cut memory **4×** at competitive generation quality.
- Implemented adaptive block-wise **FP8/FP4/NVFP4** quantization and quantization-aware training with learnable per-head cross-modal scales; evaluated trade-offs on WebVid-10M, VGGSound, and UCF-101.
- Built a **vLLM-style serving scheduler** (frame-level paged attention, dynamic frame batching) and benchmarked on **H100 GPUs** using PyTorch Profiler and Nsight to guide low-precision kernel choices.
- Research on multimodal deepfake detection using visual, audio, and temporal consistency analysis.
- M.Eng. Thesis: "Detecting Deepfake Video by a Multimodal Audio-Visual Framework with Temporal Inconsistencies."

Undergraduate Researcher, Northwestern Polytechnical University, Jan 2023 - Jul 2024
Advisor: Dr. Yaxing Chen

- Designed and built a distributed confidential-query framework on Apache Spark + CKKS homomorphic encryption, validated on a **10-node cluster**: **95% privacy preservation** and **20% performance improvement** via optimized analytics pipelines.
- B.Eng. Thesis: "Design and Implementation of a Distributed Confidential Query Protocol for Apache Spark."

PROJECTS

AI Infrastructure Portfolio, github.com/theraihanrakibb/ai-infra-portfolio

- Designed and shipped 10 Dockerized AI-infra services - LLM gateway, model serving, GPU observability, KV-cache simulation, benchmarking, quantization, tracing, and RAG - each with CI and a reproducible quickstart.

Distributed Training Launcher, github.com/theraihanrakibb/train-launcher

- Built a PyTorch distributed CLI that launches and supervises multi-node training jobs with fault detection, automatic retry, and checkpoint recovery.

TECHNICAL SKILLS

LLM Inference & Systems: SGLang, vLLM, KV Cache, PD Disaggregation, Mooncake/RDMA, Continuous Batching, RadixAttention

GPU & Performance: CUDA, CUDA C++, Triton, Nsight Systems, Nsight Compute, PyTorch Profiler, GEMM optimization, FP8/FP4/INT4

ML & Multimodal: PyTorch, Hugging Face Transformers, Diffusion/DiT, Multimodal Learning, OpenCV

Distributed Systems: PyTorch Distributed, Docker, Kubernetes, Linux, Prometheus, CI/CD

Programming: Python, C++, CUDA C++, Bash, SQL, Data Structures & Algorithms

PUBLICATIONS & HONORS

First Author — "NVFP4-DiT: Efficient 4-Bit Audio-Guided Video Diffusion Transformers for Low-Cost Video Generation" — IEEE Transactions on Neural Networks and Learning Systems (TNNLS, Q1), manuscript under review.

Honors: Chinese Government Scholarship (2024-2027); Presidential Scholarship (2020-2024); Wu Yajun Scholarship (2024); Best Undergraduate Thesis Award (2024); Outstanding Graduate (2024), NWPU; Hackathon Winner - NWPU AI Challenge (2023).

Certifications: AWS Certified Machine Learning – Specialty; Professional Scrum Master I (PSM I), Scrum.org; Deep Learning Specialization, DeepLearning.AI.

MD RAKIBUL ISLAM RAIHAN

ML 系统工程师 | 大模型推理与多模态 AI

2027 届应届 · 2027 年 7 月到岗 · 可接受异地 · 中国·西安
邮箱: raihanrakib.143@gmail.com · 电话: +86 177 2236 2949 · 微信: imeddii
GitHub: github.com/theraihanrakibb · LinkedIn: linkedin.com/in/theraihanrakib · Portfolio: theraihanrakibb.github.io



个人简介

ML 系统工程师，专注大模型推理、GPU 优化与多模态生成式 AI。在 InfiX.ai 实习期间，优化生产级大模型服务——Qwen 部署于 4× A800、DeepSeek 部署于 H200 多节点集群——通过三级 KV-cache 卸载将长上下文 TTFT 降低 8.3×（55s→6.7s），并借助基于 RDMA 的 prefill/decode 分离将稳定并发由 192→ 256 提升。作为第一作者撰写 IEEE TNNLS 论文，研究 NVFP4 4 比特音频引导视频扩散，在 H100 上实现显存降低 4×。擅长 SGLang、CUDA/Triton、低精度推理与分布式系统。

工作经历

无界智索（深圳）科技（InfiX.ai），AI 基础设施工程师实习, 深圳, 2026年4月 - 2026年6月

- 在 4× A800-80GB 上基于 Mooncake RDMA 设计并实现三级 KV-cache 卸载系统（GPU HBM → CPU DRAM → SSD），服务 Qwen3.5/3.6-27B 时将长上下文（32K+ token）首字延迟（TTFT）降低 8.3×（55s→6.7s），缓存命中率维持 **92%**。
- 通过基于 RDMA 的 KV 传输实现 2+2 GPU prefill/decode 分离，结合 RadixAttention 前缀缓存与连续批处理，将 Qwen3.6-27B 的稳定服务并发提升 33%（192→ 256 请求）。
- 修改 **SGLang** 缓存管理与内存分配内部模块（kvcacheio.py、memory_pool_host.py、hi_mamba_radix_cache.py）——覆盖 **v0.5.9**（A800）与 **v0.5.10-post2** 容器镜像（H200）——修复生产缓存故障并支持混合注意力（Mamba + 全注意力）Qwen 模型。
- 使用 **Nsight Systems** 分析 CUDA/Triton 推理：GEMM 占单步耗时 **60%**，由此将优化重心从缓存 I/O 转向计算算子；FP8 KV cache 将单 token KV 显存减半（72.9 → 36.5 KB）。
- 在 2× H200 部署 Qwen3-235B-A22B-FP8（235B MoE），并在 8× H200 上对 DeepSeek-V3.2（FP8）基准测试：**91 ms TTFT / 36 ms TPOT**（32-64 并发）、**13.16 req/s**（256 并发）。

香港安莱姆集团有限公司（Amraim Group Co., Ltd.），软件工程师实习（AI Agent），深圳, 2025年6月 - 2025年9月

- 从构想到生产部署，架构并交付两个端到端全栈应用（React 前端 + RESTful 后端服务）。
- 开发 AI Agent 自动化关键营销工作流，减少人工工作量，团队生产力提升 **25%**。

陕西龙宫智能科技有限公司（Longong），电气软件工程师实习, 西安, 2025年2月 - 2025年4月

- 基于 CODESYS 开发 PLC 实时电机控制软件，使用 Modbus、CAN 与 Ethernet/IP 协议，系统响应时间提升 **15%**，符合 IEC 61131 工业安全标准。

教育背景

软件工程硕士，软件学院，西北工业大学（985/211） - 2024年9月 - 2027年7月
GPA: 88/100, 前 1%, 中国政府奖学金, 国际学生联合会主席 (ISU)
计算机科学与技术学士，计算机学院，西北工业大学（985/211） - 2020年9月 - 2024年7月
GPA: 85/100, 前 1%, 校长奖学金, 最佳本科毕业论文奖

研究经历

研究生研究员, 西北工业大学, 2024年9月 - 至今
导师：张蓬 教授

- 开发 **NVFP4-DiT**：**4 比特音频引导视频扩散 Transformer**，自研 FP4 打包 **Triton** 算子相较 FP16 提速 **3.2 倍**（相较朴素 FP4 提速 2.1 倍），显存**降低 4 倍**，生成质量具有竞争力。
- 实现自适应分块 **FP8/FP4/NVFP4** 量化与量化感知训练（跨模态注意力可学习 per-head 缩放），并在 WebVid-10M、VGGSound 与 UCF-101 上评估质量-效率权衡。
- 构建 **vLLM 风格的服务调度器**（帧级分页注意力、动态帧批处理），并在 **H100** 上使用 PyTorch Profiler 与 Nsight 进行基准测试，指导低精度算子选型。
- 基于视觉、音频与时序一致性的多模态深度伪造检测研究。
- 硕士论文：《检测深度伪造视频：基于多模态音视频框架与时序不一致性》。

本科研究员, 西北工业大学, 2023年1月 - 2024年7月
导师：陈亚星 博士

- 基于 Apache Spark 与 CKKS 同态加密设计并实现分布式机密查询框架，在 **10 节点集群**上验证，通过优化分析管线实现**95% 隐私保护**与**20% 性能提升**。
- 本科论文：《面向 Apache Spark 的分布式机密查询协议设计与实现》。

项目

AI 基础设施代码集, github.com/theraihanrakibb/ai-infra-portfolio

- 设计并交付 10 个 Docker 化的 AI 基础设施服务——LLM 网关、模型服务、GPU 可观测性、KV-cache 模拟、基准测试、量化、链路追踪与 RAG，均配备 CI 与可复现的上手流程。

分布式训练启动器, github.com/theraihanrakibb/train-launcher

- 开发 PyTorch 分布式命令行工具，支持多节点训练任务的启动与监控，并具备故障检测、自动重试与断点恢复。

技术技能

大模型推理与系统： SGLang, vLLM, KV Cache, PD 分离, Mooncake/RDMA, 连续批处理, RadixAttention

GPU 与性能： CUDA, CUDA C++, Triton, Nsight Systems, Nsight Compute, PyTorch Profiler, GEMM 优化, FP8/FP4/INT4

机器学习与多模态： PyTorch, Hugging Face Transformers, Diffusion/DiT, 多模态学习, OpenCV

分布式系统： PyTorch Distributed, Docker, Kubernetes, Linux, Prometheus, CI/CD

编程语言： Python, C++, CUDA C++, Bash, SQL, 数据结构与算法

论文与荣誉

第一作者 — 《NVFP4-DiT：面向低成本视频生成的高效 4 比特音频引导视频扩散 Transformer》 — IEEE TNNLS（Q1），审稿中。
荣誉： 中国政府奖学金（2024-2027）；校长奖学金（2020-2024）；吴亚军奖学金（2024）；最佳本科毕业论文奖（2024）；西北工业大学优秀毕业生（2024）；NWPU AI 挑战赛黑客松冠军（2023）。
认证： AWS 认证机器学习 — 专业级；Professional Scrum Master I（PSM I），Scrum.org；Deep Learning 专项课程，DeepLearning.AI。